



카테고리 없음

[Euron] 12Week_ BLIP : Bootstrapping Language-Image..

yejji 2025. 5. 25. 14:25

1. 논문 : BLIP: Bootstrapping Language-Image Pre-training for Unified Vision-Language Understanding and Generation
2. 저자 : Junnan Li, Dongxu Li, Caiming Xiong, Steven Hoi, Salesforce Research
3. 링크 : <https://arxiv.org/pdf/2201.12086>

0. Abstract

VLP는 다양한 시각-언어 작업들에 성능 향상을 이끌어냈다.

그러나, VLP는

1. 이해 기반의 과제와 생성 기반의 과제 둘 중 하나의 과제에서만 성능 향상을 이끌어낸다.
2. 대부분 웹에서 수집한 노이즈가 많은 이미지-텍스트 쌍으로 구성된 대규모 데이터셋을 사용하기 때문에 최적의 방식이라고 할 수 없다.

이렇게 2가지의 문제점이 존재한다.

문제점들을 해결하기 위해서,

본 논문에서는 BLIP라는 모델을 제시한다.

BLIP 모델은

1. 이해 기반의 과제와 생성 기반의 과제 모두에서 유연한 전이가 가능하다.
2. Caption들을 bootstrapping하여 노이즈가 있는 웹 데이터를 효율적으로 활용한다.

* Captioner : 합성된 caption을 발생시킴 / Filter : 노이즈들을 제거함

실험 결과,

넓은 범위의 시각-언어 작업들에서 최고 성능을 달성하였다.

(이미지-텍스트 재건 : +2.7% / 이미지 captioning : +2.8% / VQA : +1.6%)

또, zero-shot 상태에서 비디오-언어 작업들에 직접적으로 전달될 때 강한 일반화 능력을 보여준다.

1. Introduction

시각-언어 사전학습은 최근에 다양한 멀티모달 작업들에서 꽤나 큰 성공을 거두었다.

하지만, 현재 존재하는 모델들은 2개의 주요 한계가 존재한다.

1. **모델 관점**에서, 대부분의 방식들은 인코더 기반의 모델 이나 인코더-디코더 모델에서 1가지를 채택한다.

하지만, 인코더 기반의 모델들은 텍스트 생성 과제에 직접적인 전이가 어렵다.

반면에, 인코더-디코더 모델들은 이미지-텍스트 검색 과제에서는 성공적으로 적용하기 어렵다.

2. **데이터 관점**에서, 데이터셋을 스케일링함으로써 얻어지는 수행 이득에도 불구하고, 웹 텍스트의 노이즈가 비전-언어 학습에 최적하지 않고, 성능 저하를 오히려 초래할 수 있다.

이러한 한계를 바탕으로, BLIP 모델을 제안한다.

BLIP는 기존의 모델들보다 더 넓은 범위의 작업들을 가능하게 하는 새로운 VLP 프레임워크이다.

BLIP는 모델 측면, 데이터 측면에 각각 1개씩, 총 2개의 새로운 개념을 제안한다.

1. **MED(Multimodal mixture of Encoder-Decoder)** : 멀티태스크 사전학습 및 유연한 전이 학습을 위한 새로운 모델 아키텍처

MED는 단일모달 인코더, 이미지 기반의 텍스트 인코더, 이미지 기반의 텍스트 디코더 모두로 작동할 수 있다.

총 3가지의 비전-언어 목적 함수(이미지, 텍스트 간의 대조 학습 / 이미지-텍스트 매칭 / 이미지 조건 텍스트 생성)로 함께 사전학습된다.

2. **CapFilter(Captioning and Filtering)** : 노이즈가 많은 이미지-텍스트 쌍으로부터 더 나은 학습을 가능하게 하는 데이터 Bootstrapping 기법

사전 학습된 MED를 2개의 모듈로 fine-tuning한다.

< 2개의 모듈 >

1. Captioner : 주어진 웹 이미지에 대한 합성 caption 생성함
2. Filter : 원래의 웹 텍스트와 합성 텍스트 모두로부터 노이즈가 있는 caption을 제거함

Captioner과 Filter을 합하면, 여러 개의 다양한 다운스트림 작업들에서 상당한 성능 향상을 달성한다.

또, Caption이 다양할수록 성능 향상 정도도 커진다.

다양한 비전-언어 작업들에 더불어, 비디오-언어 과제에서 zero-shot으로 전이했을 때에도 최첨단 성능을 달성한다.

2. Related Work

2.1 Vision-language Pre-training

VLP는 많은 양의 이미지-텍스트 쌍들로 모델을 사전학습시킴으로써 비전과 언어 작업들의 성능을 향상시킨다.

그러나, 사람이 직접 주석한 텍스트들을 얻기에는 비용이 너무 많이 들기 때문에, 대부분의 작업들은 웹 이미지와 텍스트 쌍들을 사용한다.

뿐만 아니라, 간단한 규칙 기반의 filter들을 적용할 때에도, 노이즈는 웹 텍스트에 여전히 존재한다.

그러나, 노이즈의 부정적인 영향은 데이터셋을 스케일링함으로써 얻는 성능 이득에 의해 가려진다.

본 논문은 웹 기반 텍스트의 노이즈가 비전-언어 학습에 비효율적이므로, 효과적으로 활용하고자 Capfilt를 제안한다.

그동안 비전-언어 작업들을 단일 프레임워크로 통합하려는 많은 시도들이 있었다.

가장 중요한 점은 이해 기반의 과제와 생성 기반의 과제를 모두 잘 수행이 가능한 모델 아키텍처를 설계하는 것이다.

인코더 기반의 모델과 인코더-디코더 모델들은 이해 기반의 과제, 생성 기반의 과제 모두에서 성능이 좋지 않다.

단일 통합형 인코더-디코더의 경우 모델의 성능을 제한한다.

논문에서 새로 제안한 MED의 경우 사전 학습을 간단하고 효율적으로 유지하면서도, 더 나은 유연성과 넓은 범위의 작업들에서 더 나은 성능을 달성한다.

2.2 Knowledge Distillation

KD(Knowledge Distillation)은 교사 모델의 지식을 학생 모델에 전달하여 성능을 향상시킨다.

Self-distillation은 KD의 특수한 경우로, 교사와 학생이 동일한 크기를 가진 경우이다.

대부분의 기존에 존재하던 KD는 학생 모델이 교사 모델과 동일한 클래스를 예측하도록 강제하였다.

이와 달리, 새롭게 제안된 CapFilt는 VLP의 측면에서 KD를 더 효율적인 방식으로 수행한다.

Captioner은 의미적으로 풍부한 합성된 caption을 생성하고, Filter은 노이즈가 있는 caption을 제거함으로써 지식을 전달한다.

2.3 Data Augmentation

DA(Data Augmentation)이 컴퓨터 비전에는 널리 적용되지만, 언어 작업들에 DA는 잘 적용되지 않았다.

최근에, 생성 언어 모델들이 다양한 NLP 작업들에서 예시들을 합성하였는데, 이런 저차원 언어 과제에 초점을 두는 방식들과 달리

합성된 caption들이 대규모의 비전-언어 사전학습에서 가지는 강점들을 보여준다.

3. Method

새로운 모델 아키텍처인 MED와 사전 학습 목적 함수들, 데이터셋을 bootstrapping하는 CapFilt를 처음으로 소개한다.

3.1 Model Architecture

이미지를 인코딩하기 위해 ViT를 사용한다.

이미지를 패치로 나누어 임베딩 시퀀스로 변환하고, 전체 이미지 정보를 담는 [CLS] 토큰을 추가한다.

기존의 객체 탐지기 기반 방식에 비해 ViT는 계산 효율이 더 좋고, 최근 연구들에서도 널리 사용되고 있다.

이해와 생성 능력을 동시에 갖춘 통합 모델을 사전학습하기 위해, MED라는 멀티태스크 모델을 제안한다.

MED는 다음 세 가지 기능들 중 하나로서 작동할 수 있다.

< MED의 3가지 기능 >

1. 단일모달 인코더 : 이미지와 텍스트를 분리하여 인코딩한다.

텍스트 인코더의 경우 BERT와 동일하다. (텍스트 인코더의 각 Transformer 블록에 CA를 삽입하여 시각 정보를 주입한다.)

2. 이미지 기반의 텍스트 인코더 : SA와 FFN 사이에 1개의 추가 CA층을 삽입한다.

[Encode]라는 특수 토큰은 텍스트 뒤에 붙어 출력 임베딩을 이미지-텍스트 쌍의 멀티모달로 표현한다.

3. 이미지 기반의 텍스트 디코더 : 기존의 텍스트 인코더의 양방향 어텐션을 제거하고, 단방향 인과적 SA로 교체한다.

[Decode] 토큰은 문장의 시작을 나타내기 위해 사용되고, end-of-sequence 토큰의 경우 마지막임을 나타내기 위해 사용된다.

3.2 Pre-training Objectives

사전학습 단계에서 **이해 기반 목적 2개와 생성 기반 목적 1개, 총 세 가지 목적을 함께 최적화** 한다.

이미지-텍스트 쌍마다 **무거운 연산이 필요한 Visual Transformer는 1번, Text Transformer는 3번의 forward pass를 수행하여** 각 목적에 따른 손실값을 계산한다.

Image-Text Contrastive Loss(ITC)

단일모달 인코더 활성화로, 양의 이미지-텍스트 쌍이 음의 쌍보다 더 유사한 표현을 갖도록 유도하여 이미지와 텍스트의 표현 공간을 정렬하는 것이 목적이다.

ITC loss는 모멘텀 인코더를 도입해 특성을 생성하고, 음의 쌍 안에 있을 수 있는 잠재적인 양의 쌍을 고려하기 위해 모멘텀 인코더로부터 소프트 레이블을 생성하여 학습 타겟으로 사용한다.

Image-Text Matching Loss(ITM)

이미지 기반의 텍스트 인코더의 활성화로, 입력된 이미지와 텍스트가 매칭이 되는지를 알고자 하는 게 목적이다.

ITM은 이분적인 분류 작업에서 ITM head로 양성인지 음성인지 여부를 예측한다. 더 정보적인 음성들을 찾기 위해, **hard negative mining strategy**를 적용한다. 여기서는, **contrastive 유사도가 높은 음성쌍을 더 자주 선택하여 학습에 활용한다.**

Language Modeling Loss(LM)

이미지 기반의 텍스트 디코더 활성화로, 주어진 이미지에 대해 텍스트 설명을 자동 회귀 방식으로 생성해낸다.

LM은 VLP에서 널리 사용되는 MLM loss와 달리 이미지 정보를 caption으로 전환하는 일반화 능력 학습이 가능하다.

텍스트 인코더와 디코더의 경우 SA층을 제외한 대부분의 파라미터들을 공유한다.

이는 현재 입력 토큰들을 나타내기 위해서, 인코더는 양방향, 다음 토큰 예측을 위해 인과적 어텐션을 사용하는 디코더는 단방향 어텐션을 사용하기 때문이다.

이와 달리 CA층과 FFN 함수는 동일하게 작동하며, 멀티태스크 학습의 효율성이 높아지고 학습 자원 절약이 가능하다.


3.3 CapFilt

고비용의 주석 작업으로 인해 COCO와 같은 고품질의 사람 주석 이미지-텍스트 쌍은 수가 제한적이다.

따라서 최근의 연구들은 웹에서 자동 수집한 대규모 이미지-대체 텍스트 쌍을 활용하지만, 이러 텍스트들은 이미지 내용을 정확히 설명하지 못해 노이즈가 많고 시각-언어 정렬 학습에 부적합하다.

이를 보완하고자 **CapFilt**라는 새로운 방법을 제안한다.

CapFilt 방법을 통해 웹에서 수집한 텍스트 데이터의 품질을 향상시킬 수 있다.



BLIP의 전체 구조(CapFilt)

CapFilt는 총 2가지의 모듈로 구성된다.

1. **Captioner**: 웹 이미지로부터 캡션을 생성
2. **Filter**: 노이즈가 있는 이미지-텍스트 쌍을 걸러냄

두 모듈 모두 사전학습된 MED 모델을 기반으로 COCO 데이터셋으로 간단히 fine-tuning하였다.

Captioner는 이미지 기반 텍스트 디코더로, 웹 이미지로부터 하나의 캡션을 생성하고, **Filter**는 이미지 기반 텍스트 인코더로, ITC 및 ITM 목표를 통해 텍스트가 이미지와 잘 맞는지를 판단한다.

원래 웹 텍스트와 생성된 캡션 중 이미지와 맞지 않는 노이즈 텍스트를 제거한다.

최종적으로, 필터링된 이미지-텍스트 쌍과 사람 주석 데이터를 결합해 새로운 데이터셋을 만들고,

이를 통해 새로운 모델을 사전학습한다.

4. Experiments and Discussions

사전학습의 세부사항들을 먼저 소개한다.

그리고, 제안한 방법론의 실험 결과에 대해 소개하고자 한다.

4.1 Pre-training Details

- 모델 : PyTorch / 16개의 GPU 노드 2대에서 사전학습
- 이미지 트랜스포머 : ImageNet으로 사전학습된 ViT
- 텍스트 트랜스포머 : BERT-base
- ViT-B/16과 ViT-L/16 두 가지 버전을 실험, 특별한 언급이 없는 경우 BLIP 모델은 ViT-B 기반으로 함

< 사전학습 >

- 20 epoch
- 배치 사이즈 : ViT-B - 2880 / ViT-L - 2400
- AdamW 옵티마이저(weight decay 0.05)
- 학습률 : (warm-up 이후) ViT-B - $3e-4$ / ViT-L - $2e-4$ // 선형 감쇠(rate 0.85).
- 사전학습 시 : 224×224 해상도의 랜덤 크롭 이미지
- 파인튜닝 시 : 384×384 해상도
- 총 1,400만 장의 이미지 데이터셋으로 사전학습
 - 사람 주석 데이터: COCO, Visual Genome
 - 웹 기반 데이터: Conceptual Captions, Conceptual 12M, SBU captions

4.2 Effect of CapFilt

Pre-train dataset	Bootstrap		Vision backbone	Retrieval-FT (COCO)		Retrieval-ZS (Flickr)		Caption-FT (COCO)		Caption-ZS (NoCaps)	
	C	F		TR@1	IR@1	TR@1	IR@1	B@4	CIDEr	CIDEr	SPICE
COCO+VG +CC+SBU (14M imgs)	✗	✗	ViT-B/16	78.4	60.7	93.9	82.1	38.0	127.8	102.2	13.9
	✗	✓ _B		79.1	61.5	94.1	82.8	38.1	128.2	102.7	14.0
	✓ _B	✗		79.7	62.0	94.4	83.6	38.4	128.9	103.4	14.2
	✓ _B	✓ _B		80.6	63.1	94.8	84.9	38.6	129.7	105.1	14.4
COCO+VG +CC+SBU +LAION (129M imgs)	✗	✗	ViT-B/16	79.6	62.0	94.3	83.6	38.8	130.1	105.4	14.2
	✓ _B	✓ _B		81.9	64.3	96.0	85.0	39.4	131.4	106.3	14.3
	✓ _L	✓ _L		81.2	64.1	96.0	85.5	39.7	133.3	109.6	14.7
	✗	✗	ViT-L/16	80.6	64.1	95.1	85.5	40.3	135.5	112.5	14.7
	✓ _L	✓ _L		82.4	65.1	96.7	86.7	40.4	136.7	113.2	14.8

CapFilt의 효과

Bootstrap C와 F를 함께 적용한 경우, 기존의 노이즈가 있는 웹 텍스트들을 사용한 경우보다 상당한 성능 향상을 이끌어낸다.

Capfilt는 크기가 더 큰 데이터셋과 vision backbone의 성능 더 향상 가능하다.

게다가, ViT-L로 더 큰 Captioner과 Filter를 사용한 경우 베이스 모델의 성능이 더 향상될 수 있다.



Figure 4. Examples of the web text T_w and the synthetic text T_s . Green texts are accepted by the filter, whereas red texts are rejected.

Captioner의 효과 + Filter의 효과

Captioner은 새로운 텍스트 묘사를 만들어내고,

Filter의 경우 원래의 웹 텍스트와 합성 텍스트에서 노이즈가 있는 caption들을 제거한다.

T_w 는 web text를 T_s 는 synthetic text를 의미한다.

이미지와 text가 잘 맞는다고 판단되는 경우에 해당 text를 받아들리게 된다.

초록색 글씨는 filter가 받아들인 text를, 빨간색 글씨는 filter가 받아들이지 않은 text를 의미한다.

4.3 Diversity is Key for Synthetic Captions

CapFilter에서 합성 caption을 생성하기 위해 nucleus sampling을 적용한다.

Nucleus sampling은 누적 확률 질량이 특정 임계값 ($p = 0.9$)을 초과하는 토큰 집합에서 무작위로 토큰을 선택하는 확률적 디코딩 기법이다.

Generation method	Noise ratio	Retrieval-FT (COCO)		Retrieval-ZS (Flickr)		Caption-FT (COCO)		Caption-ZS (NoCaps)	
		TR@1	IR@1	TR@1	IR@1	B@4	CIDEr	CIDEr	SPICE
None	N.A.	78.4	60.7	93.9	82.1	38.0	127.8	102.2	13.9
Beam	19%	79.6	61.9	94.1	83.1	38.4	128.9	103.5	14.2
Nucleus	25%	80.6	63.1	94.8	84.9	38.6	129.7	105.1	14.4

Beam search vs Nucleus sampling

결정론적인 디코딩 방법인 Beam Search와 비교하였다.

실험 결과, Nucleus Sampling이 Beam Search와 비교하였을 때 더 좋은 성능을 보였다.

Nucleus Sampling은 필터를 통해 측정된 노이즈 비율이 25%로 더 높음에도 불구하고 성능이 뛰어나다는 것을 알 수 있었다.

이는 **Nucleus Sampling**이 더 다양하고 놀라운 캡션을 생성해 새로운 정보를 모델에 제공하기 때문이다.

반면에, **Beam Search**는 데이터셋에서 흔히 볼 수 있는 안전한 캡션을 생성하기 때문에 추가적인 지식을 덜 제공한다고 봅니다.

4.4 Parameter Sharing and Decoupling

사전 학습 과정에서 텍스트 디코더와 인코더는 SA층을 제외한 모든 파라미터들을 공유한다.

Layers shared	#parameters	Retrieval-FT (COCO)		Retrieval-ZS (Flickr)		Caption-FT (COCO)		Caption-ZS (NoCaps)	
		TR@1	IR@1	TR@1	IR@1	B@4	CIDEr	CIDEr	SPICE
All	224M	77.3	59.5	93.1	81.0	37.2	125.9	100.9	13.1
All except CA	252M	77.5	59.9	93.1	81.3	37.4	126.1	101.2	13.1
All except SA	252M	78.4	60.7	93.9	82.1	38.0	127.8	102.2	13.9
None	361M	78.3	60.5	93.6	81.9	37.8	127.4	101.8	13.9

Parameter sharing strategy에 따른 사전학습된 모델 평가

None 경우와 All except SA 경우를 비교하였을 때, **All except SA 경우가 None 경우보다 성능이 더 좋다**는 것을 알 수 있었다.

(모델의 사이즈를 줄이는 경우에도 학습 효율을 향상시킨다.)

또, All except CA 와 같이 **SA층을 공유하는 경우에는 성능이 상대적으로 저하되었다**는 사실도 확인할 수 있었다.

이는 encoding task와 decoding task의 충돌이 원인으로 작용한다.

CapFilt 과정에서 Captioner와 Filter를 COCO 데이터셋에서 각각 개별적으로 end-to-end fine-tuning한다.

Captioner & Filter	Noise ratio	Retrieval-FT (COCO)		Retrieval-ZS (Flickr)		Caption-FT (COCO)		Caption-ZS (NoCaps)	
		TR@1	IR@1	TR@1	IR@1	B@4	CIDEr	CIDEr	SPICE
Share parameters	8%	79.8	62.2	94.3	83.7	38.4	129.0	103.5	14.2
Decoupled	25%	80.6	63.1	94.8	84.9	38.6	129.7	105.1	14.4

Captioner과 Filter가 파라미터들을 공유하는 방식 vs Decoupling 방식 사용 경우의 성능 비교

Captioner 과 Filter가 파라미터를 공유할 경우, 다운스트림 작업들의 성능이 전체적으로 감소하고,

이는 Confirmation bias(확증 편향) 때문이라고 설명한다.

파라미터를 공유할 경우 Captioner가 생성한 노이즈가 있는 caption들이 Filter에 의해 걸러질 가능성이 낮아지게 된다.

이는, Share parameters 방식의 noise ratio가 25% 에서 8%로 감소한 수치에서 확인 가능하다.

5. Comparison with State-of-the-arts

넓은 범위의 비전-언어 다운스트림 작업들에서 BLIP를 기존에 존재하던 VLP 방식들과 비교하였다.

5.1 Image-Text Retrieval

BLIP를 COCO 데이터셋과 Flickr30K 데이터셋에서 TR과 IR 모두에서 평가한다.

더 빠른 추론이 가능하도록 이미지-텍스트 특징 유사도에 기반하여 k개의 candidate들을 먼저 선택한다.

그 후 선택한 candidate들을 그들의 쌍별 ITM score들과 비교하여 재순위화한다.

* COCO 데이터셋에 대해 k = 256, Flickr30K에 대해 k = 128로 설정하였다.

Method	Pre-train # Images	COCO (5K test set)						Flickr30K (1K test set)					
		TR			IR			TR			IR		
UNITER (Chen et al., 2020)	4M	R@1	R@5	R@10	R@1	R@5	R@10	R@1	R@5	R@10	R@1	R@5	R@10
VILLA (Gan et al., 2020)	4M	65.7	88.6	93.8	52.9	79.9	88.0	87.3	98.0	99.2	75.6	94.1	96.8
OSCAR (Li et al., 2020)	4M	-	-	-	-	-	-	87.9	97.5	98.8	76.3	94.2	96.8
UNIMO (Li et al., 2021b)	5.7M	70.0	91.1	95.5	54.0	80.8	88.5	-	-	-	-	-	-
ALIGN (Jia et al., 2021)	1.8B	-	-	-	-	-	-	89.4	98.9	99.8	78.0	94.2	97.1
ALBEF (Li et al., 2021a)	14M	77.0	93.5	96.9	59.9	83.3	89.8	95.3	99.8	100.0	84.9	97.4	98.6
		77.6	94.3	97.2	60.7	84.3	90.5	95.9	99.8	100.0	85.6	97.5	98.9
BLIP	14M	80.6	95.2	97.6	63.1	85.3	91.1	96.6	99.8	100.0	87.2	97.5	98.8
BLIP	129M	81.9	95.4	97.8	64.3	85.7	91.5	97.3	99.9	100.0	87.3	97.6	98.9
BLIP _{CapFilt-L}	129M	81.2	95.7	97.9	64.1	85.8	91.6	97.2	99.9	100.0	87.5	97.7	98.9
BLIP _{ViT-L}	129M	82.4	95.4	97.9	65.1	86.3	91.8	97.4	99.8	99.9	87.6	97.7	99.0

BLIP vs 기존의 방식들의 성능 비교

같은 14M의 사전 학습 이미지들을 사용하였을 때,

In COCO, BLIP는 average recall@ 1에서 기존의 최고 성능 모델인 ALBEF를 2.7% 증가하였다.

In COCO, fine-tuning한 모델을 그대로 Flickr30K에 적용하여 zero-shot retrieval을 수행하였다.

Method	Pre-train # Images	Flickr30K (1K test set)					
		TR			IR		
		R@1	R@5	R@10	R@1	R@5	R@10
CLIP	400M	88.0	98.7	99.4	68.7	90.6	95.2
ALIGN	1.8B	88.6	98.7	99.7	75.7	93.8	96.8
ALBEF	14M	94.1	99.5	99.7	82.8	96.3	98.1
BLIP	14M	94.8	99.7	100.0	84.9	96.7	98.3
BLIP	129M	96.0	99.9	100.0	85.0	96.8	98.6
BLIP _{CapFilt-L}	129M	96.0	99.9	100.0	85.5	96.8	98.7
BLIP _{ViT-L}	129M	96.7	100.0	100.0	86.7	97.3	98.7

BLIP vs 기존 방식들의 성능 비교

BLIP가 기존의 방식들을 증가하였다는 사실을 다시 확인 가능하다.

5.2 Image Captioning

Image Captioning에 대하여 2가지의 데이터셋을 고려하였다.

No-Caps와 COCO 2가지인데, 두 데이터셋 모두 COCO 데이터셋에서 LM loss값으로 fine-tuning된 모델로 평가되었다.

각 Caption의 시작 부분에 " a picture of "를 추가하였다.

이는 약간 더 나은 결과를 이끌어낸다.

Method	Pre-train #Images	NoCaps validation								COCO Caption Karpathy test	
		in-domain		near-domain		out-domain		overall		B@4	C
Enc-Dec (Changpinyo et al., 2021)	15M	92.6	12.5	88.3	12.1	94.5	11.9	90.2	12.1	-	110.9
VinVL [†] (Zhang et al., 2021)	5.7M	103.1	14.2	96.1	13.8	88.3	12.1	95.5	13.5	38.2	129.3
LEMON _{base} [†] (Hu et al., 2021)	12M	104.5	14.6	100.7	14.0	96.7	12.4	100.4	13.8	-	-
LEMON _{base} [†] (Hu et al., 2021)	200M	107.7	14.7	106.2	14.3	107.9	13.1	106.8	14.1	40.3	133.3
BLIP	14M	111.3	15.1	104.5	14.4	102.4	13.7	105.1	14.4	38.6	129.7
BLIP	129M	109.1	14.8	105.8	14.4	105.7	13.7	106.3	14.3	39.4	131.4
BLIP _{CapFilt-L}	129M	111.8	14.9	108.6	14.8	111.5	14.2	109.6	14.7	39.7	133.3
LEMON _{large} [†] (Hu et al., 2021)	200M	116.9	15.8	113.3	15.1	111.3	14.0	113.4	15.0	40.6	135.7
SimVLM _{huge} (Wang et al., 2021)	1.8B	113.7	-	110.9	-	115.2	-	112.2	-	40.6	143.3
BLIP _{VIT-L}	129M	114.9	15.2	112.1	14.9	115.3	14.4	113.2	14.8	40.4	136.7

NoCaps와 COCO Caption에서 image captioning 방식들의 성능 비교

14M의 사전학습 이미지들을 가지는 BLIP가 비슷한 양의 사전학습 데이터를 사용한 방식들을 상당히 능가하였다.

129M의 이미지를 가지는 BLIP는 200M의 이미지를 가지는 LEMON의 성능보다 좀 더 경쟁적 성능을 가진다.

LEMON의 경우 계산량이 많은 사전학습된 detector을 필요로 하고, 더 높은 입력 이미지 해상도를 필요로 한다.

이는 detector가 필요없는 BLIP과 비교하였을 때, 상당히 더 느린 추론 시간으로 이어진다.

5.3 Visual Question Answering (VQA)

VQA는 주어진 이미지와 질문에 대하여 대답을 예측하는 모델을 필요로 한다.

VQA를 다중 정답 분류 문제가 아닌 정답 생성 작업으로 구성하여 개방형 VQA가 가능하도록 하였다.




그림 (a)에서처럼, fine-tuning 시 이미지-질문 쌍을 멀티모달 임베딩으로 인코딩한 후에, 이를 정답 디코더에 전달한다.

모델은 정답 생성 시 LM loss를 사용해 학습된다.

Method	Pre-train #Images	VQA		NLVR ²	
		test-dev	test-std	dev	test-P
LXMERT	180K	72.42	72.54	74.90	74.50
UNITER	4M	72.70	72.91	77.18	77.85
VL-T5/BART	180K	-	71.3	-	73.6
OSCAR	4M	73.16	73.44	78.07	78.36
SOHO	219K	73.25	73.47	76.37	77.32
VILLA	4M	73.59	73.67	78.39	79.30
UNIMO	5.6M	75.06	75.27	-	-
ALBEF	14M	75.84	76.04	82.55	83.14
SimVLM _{base} [†]	1.8B	77.87	78.14	81.72	81.77
BLIP	14M	77.54	77.62	82.67	82.30
BLIP	129M	78.24	78.17	82.48	83.08
BLIP _{CapFilt-L}	129M	78.25	78.32	82.15	82.24

VQA와 NLVR에서 BLIP vs 기존의 방식들 성능 비교

14M의 이미지들을 사용하였을 때, BLIP는 ALBEF를 테스트셋 측면에서 +1.64%의 성능을 달성하였다.

129M의 이미지들을 사용하였을 때, BLIP는 13XM의 데이터셋을 사용한 SimVLM보다 성능이 뛰어나다.

5.4 Natural Language Visual Reasoning (NLVR)

NLVR은 문장이 두 개의 이미지를 잘 설명하는지를 예측하는 과제이다.

2개의 이미지를 함께 추론 가능하도록, BLIP는 사전학습된 모델에 간단한 구조 변경을 적용하여 기존 방법들보다 계산 효율적인 아키텍처를 구성하였다.


(b) NLVR²

그림 (b)와 같이, 이미지 기반 텍스트 인코더의 각 트랜스포머 블록에는 두 개의 이미지에 대한 크로스 어텐션(CA) 레이어가 있으며, 각 출력값은 1개로 병합되어 FFN에 전달된다.

2개의 CA층은 사전학습된 같은 가중치값으로부터 초기화된다.

초기 6개 레이어에서는 average pooling으로 병합하고, 이후 6~12 레이어에서는 Concatenation 이후에 선형 변환을 적용한다.

최종적으로 [Encode] 토큰의 출력에 MLP 분류기를 적용한다.

Method	Pre-train #Images	VQA		NLVR ²	
		test-dev	test-std	dev	test-P
LXMERT	180K	72.42	72.54	74.90	74.50
UNITER	4M	72.70	72.91	77.18	77.85
VL-T5/BART	180K	-	71.3	-	73.6
OSCAR	4M	73.16	73.44	78.07	78.36
SOHO	219K	73.25	73.47	76.37	77.32
VILLA	4M	73.59	73.67	78.39	79.30
UNIMO	5.6M	75.06	75.27	-	-
ALBEF	14M	75.84	76.04	82.55	83.14
SimVLM _{base} [†]	1.8B	77.87	78.14	81.72	81.77
BLIP	14M	77.54	77.62	82.67	82.30
BLIP	129M	78.24	78.17	82.48	83.08
BLIP _{CapFilt-L}	129M	78.25	78.32	82.15	82.24

VQA와 NLVR에서 BLIP vs 기존의 방식들 성능 비교

BLIP는 특성에 맞추어 사전학습된 ALBEF를 제외하고는 모든 기존의 방식들을 능가한다.

신기하게도, NLVR은 웹 이미지를 추가로 사용해도 성능 향상이 크지 않았다.

이는 웹 데이터와 실제 다운스트림 작업 데이터 간의 도메인 차이(domain gap) 때문이라고 예상된다.

5.5 Visual Dialog (VisDial)

VisDial은 VQA를 자연스러운 대화 형태로 확장한 과제로, 이미지와 질문뿐만 아니라 대화 이력과 이미지 캡션까지 고려하여 답변을 예측해야 한다.

본 연구에서는 정답 후보들을 순위별로 매기는 **판별 기반(discriminative)** 설정을 따른다.




그림 (c)에서처럼, 이미지와 Caption Embedding을 연결하여 Dialog Encoder에 cross-attention을 통해 전달한다.

이후 전체 대화 이력과 이미지-캡션 정보를 바탕으로 주어진 정답이 맞는지 판단하기 위해 ITM loss로 학습한다.

Method	MRR↑	R@1↑	R@5↑	R@10↑	MR↓
VD-BERT	67.44	54.02	83.96	92.33	3.53
VD-ViLBERT†	69.10	55.88	85.50	93.29	3.25
BLIP	69.41	56.44	85.90	93.30	3.20

BLIP vs VisDial 성능 비교

BLIP가 VisDial v1.0의 성능을 능가하였다.

5.6 Zero-shot Transfer to Video-Language Tasks

BLIP는 비디오-언어 작업들에서도 강한 일반화 능력을 가진다.

Method	R1↑	R5↑	R10↑	MdR↓
<i>zero-shot</i>				
ActBERT (Zhu & Yang, 2020)	8.6	23.4	33.1	36
SupportSet (Patrick et al., 2021)	8.7	23.0	31.1	31
MIL-NCE (Miech et al., 2020)	9.9	24.0	32.4	29.5
VideoCLIP (Xu et al., 2021)	10.4	22.2	30.0	-
FiT (Bain et al., 2021)	18.7	39.5	51.6	10
BLIP	43.3	65.6	74.7	2
<i>finetuning</i>				
ClipBERT (Lei et al., 2021)	22.0	46.8	59.9	6
VideoCLIP (Xu et al., 2021)	30.9	55.4	66.8	-

Text-to-video retrieval 성능 비교

Method	MSRVTT-QA	MSVD-QA
<i>zero-shot</i>		
VQA-T (Yang et al., 2021)	2.9	7.5
BLIP	19.2	35.2
<i>finetuning</i>		
HME (Fan et al., 2019)	33.0	33.7
HCRN (Le et al., 2020)	35.6	36.1
VQA-T (Yang et al., 2021)	41.5	46.3

Video question answering 성능 비교

Test-to-video retrieval과 video question answering에 Zero-shot transfer를 적용하였다.

비디오의 입력 처리는 매우 단순하게, 각 비디오에서 프레임을 균일하게 n 개를 ($n=8, 16$) 샘플링한 후 하나의 시퀀스로 연결하여 사용한다.

이 방식은 시간적 정보(temporal information)를 완전히 무시한다.

Domain gap과 시간 정보를 미사용했음에도 불구하고 BLIP는 2개의 비디오-언어 과제 모두에서 최신 성능을 달성하였다.

특히 text-to-video retrieval에서는, **zero-shot BLIP**가 대상 비디오 데이터셋에서 **fine-tuning된 모델**보다도 **Recall@1에서 +12.4%가 높은 성능을 달성하였다.**

추가적인 성능 향상을 위해서는, BLIP를 시간 정보를 처리할 수 있는 모델(**TimeSformer**)로 확장하여 비디오 데이터에 fine-tuning하여 더 높은 성능을 기대할 수 있다.

6. Additional Ablation Study

CapFilt에 대한 추가적인 연구들을 제공한다.

Improvement with CapFilt is not due to longer training.

Bootstrap된 데이터셋은 데이터셋 자체에 text가 더 많아서 같은 에폭수로 training시 시간이 더 오래 걸린다.

CapFilt의 효과가 단순히 더 긴 학습 때문이 아님을 확인하기 위해, 원래의 웹 텍스트 데이터를 부트스트랩된 데이터셋과 동일한 학습 샘플 수를 갖도록 복제하여 실험을 진행하였다.

CapFilt	#Texts	Retrieval-FT (COCO)		Retrieval-ZS (Flickr)		Caption-FT (COCO)		Caption-ZS (NoCaps)	
		TR@1	IR@1	TR@1	IR@1	B@4	CIDEr	CIDEr	SPICE
No	15.3M	78.4	60.7	93.9	82.1	38.0	127.8	102.2	13.9
No	24.7M	78.3	60.5	93.7	82.2	37.9	127.7	102.1	14.0
Yes	24.7M	80.6	63.1	94.8	84.9	38.6	129.7	105.1	14.4

CapFilt 적용 여부 & 텍스트 수에 따른 성능 비교

노이즈가 많은 웹 텍스트로 학습 시간을 늘려도 성능 향상은 확인할 수 없었다.

즉, CapFilt의 효과가 단순히 더 긴 학습 때문이 아님을 확인할 수 있었다.

A New model Should be trained on the bootstrapped dataset.

Bootstrap된 데이터셋은 새로운 모델의 사전학습에 사용된다.

기존 사전학습된 모델에서 계속 학습(continue training)하는 방식의 효과를 실험하였다.

Continue	Retrieval-FT (COCO)		Retrieval-ZS (Flickr)		Caption-FT (COCO)		Caption-ZS (NoCaps)	
	TR@1	IR@1	TR@1	IR@1	B@4	CIDEr	CIDEr	SPICE
Yes	80.6	63.0	94.5	84.6	38.5	129.9	104.5	14.2
No	80.6	63.1	94.8	84.9	38.6	129.7	105.1	14.4

Continue training 유무에 따른 성능 비교

Continue training은 성능 향상에 일조하지 않는다.

이는 Knowledge distillation에서 학생 모델이 교사 모델로부터 초기화되지 않는다는 일반적인 관찰과 일치한다.

7. Conclusion

본 논문은 다양한 비전-언어 과제에서 최첨단 성능을 달성하는 새로운 VLP 프레임워크인 **BLIP**를 제안한다.

BLIP는 대규모의 노이즈 이미지-텍스트 쌍에서 bootstrap된 데이터셋을 활용해, 다양한 합성 caption을 주입하고 노이즈 캡션을 제거하여 multimodal encoder-decoder 모델을 사전학습한다.

추가적으로 BLIP의 성능을 더욱 향상시킬 수 있는 몇 가지 가능성 있는 방향도 제시하였다.

1. 데이터셋 부트스트래핑을 여러 번 반복함
2. 이미지당 여러 개의 합성 캡션 생성으로 사전학습 데이터 확대함
3. 다양한 캡셔너와 필터를 조합해 앙상블 방식의 CapFilt 구현함

본 논문이 모델과 데이터 양측 측면 모두에서 비전-언어 연구의 발전을 자극하길 기대하며 논문을 마무리한다.