

대규모 언어모델(LLM)은 Human Feedback을 통해 더 유용하고, 사실적이고, 윤리적인 출력을 생성하도록 정렬된다. 대표적인 정렬 기법으로는 강화학습 기반 정렬인 RLHF와 DPO인데, 둘 다 단순한 지도 학습(SFT) 보다 훨씬 더 좋은 성능을 보인다. 그러나 두 방법 모두 선호 데이터를 요구하는데, 이 데이터가 수집이 어렵고 비용이 많이 드는 게 문제이다.

인간 피드백은 단순한 선호 형태가 아니라 긍정/부정 같은 방식으로 제공될 수 있다.

하지만, RLHF와 DPO는 선호 형식의 데이터만 사용하도록 설계되어 있다.

이 논문에서는 왜 RLHF, DPO 방식이 효과적인지 랑 선호가 꼭 필요한지를 행동경제학 이론인 기대이론을 통해 분석한다.

기대이론은 사람들은 기댓값 최적화 대신, 손실 회피 등의 편향된 방식으로 선택을 한다는 이론이다. 예를 들어, 같은 금액의 이득보다 손실에 더 민감하게 반응한다는 것이다.

이를 바탕으로 논문은 DPO와 같은 기존의 정렬 알고리즘들이 기대이론의 인간적 편향을 내재하고 있었기 때문에 성능이 좋았던 것이라고 주장한다.

이와 관련하여 HALO 를 제안하였다.

인간 편향을 의도적으로 반영한 손실 함수를 HALO라고 정의하는데, HALO가 반드시 기존 방법보다 좋다고 무조건 말할 수는 없지만, 실험을 진행했을 때 HALO를 만족하는 손실 함수가 더 좋은 성능을 보였다는 것을 확인하였다.

다음으로 KTO를 제안한다.

KTO는 기대이론을 수학적으로 적용한 새로운 정렬 방식인데, DPO처럼 선호 데이터를 쓰는 대신에, 이 출력이 좋은지/나쁜지 만을 구분하는 이진 피드백만 사용한다.

이진 피드백이 수집이 훨씬 쉽고 저렴하기 때문에 이를 활용하면 실제 응용 환경에서 더 빠르게 정렬이 가능하다.

실험을 진행해보면, DPO의 성능과 비교했을 때 특정 파라미터 범위에서 DPO와 성능이

비슷하거나 더 좋았고, 90% 정도가 더 적은 긍정 데이터만으로도 DPO와 같은 성능을 달성하였다. 뿐만 아니라, 지도학습이 필요한 DPO와 달리 KTO는 지도학습 없이도 바로 사용이 가능하다는 장점이 있다.

결론적으로 KTO는 약한 피드백만으로도 우수한 정렬 결과를 낼 수 있었다. 하지만 모든 상황에서 KTO나 HALO가 무조건 좋은 것은 아니기 때문에 상황에 따라 가장 적합한 HALO를 선택하는 게 필요하다.